

CP2 отчёт: прогноз ETH/USD на 1 минуту вперёд

Холодилов Семён Максимович, БИВ238

2026-05-09

1. Постановка задачи

Цель проекта - предсказать цену закрытия Ethereum к доллару США на следующей минуте по минутным OHLCV-свечам. Это задача регрессии временного ряда: по информации, доступной на момент t , строится прогноз $\text{Close}(t+1)$.

Основная метрика - **MAE**. Она измеряется в долларах и напрямую показывает среднюю абсолютную ошибку прогноза. Дополнительно считаются RMSE и R2. Для выбора модели использовался validation split, test split использовался только для финальной оценки.

Важно: это учебная ML-задача, а не торговая рекомендация. Модель не учитывает комиссии, спреда, проскальзывание, новости и изменение рыночного режима.

2. Данные

В CP2-прогоне использован файл `data/sample/ethusd_1m_sample.csv`. Факты из `report/dataset_description.json`

- строк: 120000;
- колонок после удаления служебных полей: 10;
- период: с 2025-07-20 03:05:00 по 2025-10-11 11:04:00;
- пропуски во всех используемых колонках: 0.

Использованные исходные колонки: `Open time`, `Open`, `High`, `Low`, `Close`, `Volume`, `Quote asset volume`, `Number of trades`, `Taker buy base asset volume`, `Taker buy quote asset volume`.

Для самостоятельного получения данных добавлен скрипт `scripts/download_binance_klines.py`. В локальном контрольном запуске из логов он сохранил 121 строку в `data/raw/ethusdt_1m_binance_api_check.csv` за период 2025-01-01 00:00:00 - 2025-01-01 02:00:00. Основные эксперименты ниже проводились не на этом маленьком API-чеке, а на `sample` из 120000 строк.

3. Очистка данных и выбросы

Очистка реализована в `src/eth_price/data.py`. По `report/cleaning_report.json` для CP2-прогона:

- bad timestamps: 0;
- дубликаты timestamp: 0;
- строки с некорректной OHLCV-логикой: 0;
- разрывы временного ряда не по 1 минуте: 0;
- строк после очистки: 120000.

Отдельно проверялись экстремальные минутные log-return. По `report/outlier_report.json` найдено 186 наблюдений с порогом `z_threshold = 6.0`, доля - 0.001550, максимальный абсолютный log-return - 0.045160.

Эти наблюдения не удалялись автоматически, потому что для криптовалют резкие минутные движения могут быть реальными рыночными событиями. Автоматически удаляются только физически невозможные записи: отрицательные цены/объёмы, нарушение `Low <= Open/Close`

<= High, плохие timestamps и дубликаты. Распределительные выбросы обрабатываются внутри sklearn-pipeline через QuantileClipper, который обучается только на train split.

4. Feature engineering и защита от data leakage

После feature engineering осталось 119938 строк и 118 признаков. Добавлены candle-признаки, торговые отношения, лаги цены/объёма/сделок/доходности, rolling-признаки по окнам 5/15/30/60 минут, EMA, RSI-14 и временные признаки.

Data leakage контролируется так:

1. Split хронологический: train, затем validation, затем test. Перемешивания нет.
2. Target создаётся как $\text{Close}(t+1)$ через $\text{shift}(-1)$ и не входит в признаки.
3. Лаговые и rolling-признаки используют только текущее или прошлое значение на момент t .
4. Препроцессинг и подбор параметров выполняются на train/validation. Test используется только один раз для финальной оценки.

5. Визуализации и выводы




Figure 1: История цены

Цена меняется плавно относительно горизонта 1 минута. Поэтому текущая цена $\text{Close}(t)$ является сильным baseline для прогноза $\text{Close}(t+1)$.

Большая часть минутных доходностей около нуля, но есть хвосты. Из-за этого RMSE чувствителен к редким крупным движениям, а MAE удобнее как основная метрика средней ошибки.

Самые сильные связи с target имеют текущие и лаговые ценовые признаки. Это ожидаемо для короткого горизонта и объясняет, почему сложные модели не обязаны сильно обгонять naive baseline.

РСА показывает сильную избыточность признаков: многие лаги и rolling-признаки коррелируют между собой. Поэтому в эксперименты добавлена модель Ridge+РСА95.




Figure 2: Распределение log-return

6. Эксперименты

Использовались два baseline:

1. Baseline LinearRegression without FE - линейная регрессия на исходных OHLCV-признаках без feature engineering.
2. Naive close(t) - прогноз $\text{Close}(t+1) = \text{Close}(t)$. Для минутных финансовых данных это обязательный сильный baseline.

Каждый эксперимент запускался на одинаковом хронологическом split. Подбор гиперпараметров выполнялся по validation MAE без доступа к test. Полная таблица экспериментов сохранена в `report/experiment_results.csv`, полный лог перебора параметров - в `report/hyperparameter_search_details.csv`.

Model	Val MAE	Test MAE	Test RMSE	Короткий вывод
Baseline LinearRegression without FE	1.8759	2.3501	4.4084	baseline без FE
Weighted blend: naive + Ridge	1.8766	2.3469	4.3796	лучший RMSE, финальный ансамбль
Naive close(t)	1.8767	2.3458	4.3833	лучший MAE
Ridge	1.8877	2.4123	4.8587	лучшая ML-модель внутри blend
ElasticNet	1.8888	2.3910	4.7675	близко к линейным моделям

Model	Val MAE	Test MAE	Test RMSE	Короткий вывод
LinearRegression	1.8893	2.3922	4.7594	FE не дал сильного выигрыша
Ridge+PCA95	2.0069	2.5646	5.5623	PCA ухудшил качество
RandomForest	2.6785	2.7207	4.6479	хуже линейных моделей
ExtraTrees	2.7043	2.8806	5.5024	хуже линейных моделей

Перебор параметров был выполнен для Ridge (alpha: 0.1, 1.0, 10.0, 50.0), ElasticNet (alpha: 0.0001/0.001 при l1_ratio=0.2), Ridge+PCA95 (alpha: 0.1, 1.0, 10.0). Для RandomForest и ExtraTrees использовалась ограниченная конфигурация n_estimators=10, max_depth=8, min_samples_leaf=5, чтобы эксперимент был воспроизводимым на минутных данных.

7. Финальная модель CP2 и честная интерпретация результата

По test MAE лучший результат показал Naive close(t): test_mae = 2.3458. Это означает, что на горизонте 1 минута простая инерционная модель очень сильна.

Weighted blend: naive + Ridge получил test_mae = 2.3469, то есть по MAE он немного хуже naive baseline. При этом он получил лучший test_rmse = 4.3796 против 4.3833 у naive baseline. Улучшение RMSE очень маленькое, примерно 0.084%.

Поэтому честный вывод такой: сложные ML-модели в этом CP2-прогоне не дали существенного улучшения над naive baseline. В качестве финальной CP2-модели можно оставить weighted blend, потому что он является ансамблем, использует ML-поправку Ridge и слегка снижает RMSE. Но в отчёте нельзя утверждать, что ML существенно превзошёл baseline.

8. Качество кода и воспроизводимость

В архиве есть pyproject.toml, requirements.txt, fixed seed SEED = 812742, Dockerfile, docker-compose, тесты, модульная структура src/eth_price/, скрипт обучения scripts/train.py и скрипт самостоятельного парсинга scripts/download_binance_klines.py.

Проверки, выполненные при сборке этого CP2-архива:

```
ruff check .
ruff format --check .
PYTHONPATH=src pytest -q
```

Результат: ruff проходит, pytest - 4 passed.

9. Итог CP2

Что реально закрыто в CP2: проверка выбросов, объяснение защиты от data leakage, самостоятельный парсер Binance API, 5+ моделей, ансамбль Weighted blend: naive + Ridge, перебор гиперпараметров, PCA-эксперимент, линтер, Dockerfile/docker-compose и тесты.

Главный содержательный вывод: для Close(t+1) на минутном горизонте ETH/USD текущая цена является настолько сильным ориентиром, что сложные модели почти не улучшают качество. Это не провал проекта, а корректный результат эксперимента для выбранного горизонта.




Figure 3: Корреляционная матрица




Figure 4: PCA explained variance