

CP3 отчёт: прогнозирование цены ETHUSD

Студент: Семён

Проект: прогнозирование следующей минутной цены закрытия ETHUSD по минутным свечам Binance

Версия отчёта: CP3

1. Введение и постановка задачи

Задача проекта — построить сервис, который по последним минутным свечам ETHUSD выдаёт прогноз цены закрытия следующей минуты. Это регрессионная ML-задача: таргет — Close следующей свечи.

Основная метрика — RMSE в долларах. Она выбрана потому, что ошибка измеряется в тех же единицах, что и цена, а крупные промахи штрафуются сильнее. Дополнительно считаются MAE, MAPE и directional accuracy. Directional accuracy оставлена как вспомогательная метрика: для возможного торгового применения важно направление, но в этом проекте я не заявляю торговую стратегию.

2. Поиск и описание данных

Использован файл ETHUSD_1m_Binance.csv из архива ETHUSD_1m_Binance.zip. Это минутные OHLCV-свечи по ETHUSD.

Краткое описание данных:

- строк всего: 4,278,673;
- столбцов: 12;
- период: 2017-08-17 04:00:00 — 2025-10-11 11:04:00;
- исходные признаки: Open, High, Low, Close, Volume, Quote asset volume, Number of trades, taker-buy объёмы и время свечи.

Для быстрого контрольного пересчёта CP3 использован последний срез в 50,000 строк: 2025-09-06 17:45:00 — 2025-10-11 11:04:00. Это не замена полного CP2-обучения, а воспроизводимая проверка для деплоя и отчёта.

3. Обработка и подготовка данных

Что сделано:

- даты приведены к datetime;
- числовые колонки приведены к числовому типу;
- в проверочном срезе пропусков не найдено;
- в проверочном срезе дублей не найдено;
- колонка Ignore не используется;
- сплит сделан строго по времени: train/validation/test = 70/15/15, без перемешивания.

Feature engineering:

- лаги цены закрытия: 1, 5, 10, 30, 60 минут;
- лаги минутной доходности;
- относительный спред High-Low;
- изменение Close относительно Open;
- логарифмы объёма, quote volume и числа сделок;
- доли taker-buy объёмов;
- rolling mean и rolling std на окнах 5, 15 и 60 минут;

- циклические признаки часа: `hour_sin`, `hour_cos`.

Всего в деплойном артефакте используется 35 признаков.




Figure 1: Динамика цены на последнем срезе

4. Baseline-модель

Главный baseline — persistence: прогноз следующего Close равен текущему Close. Для минутных финансовых данных это очень сильная проверка, потому что цена за одну минуту часто меняется мало.

На validation persistence-baseline показал лучший RMSE: 2.8433 USD. Это важный результат: сложная модель не должна считаться полезной, если она не обгоняет такой простой baseline.

5. Эксперименты

Каждый эксперимент проверялся одинаково: обучение на train-части, оценка на validation-части, без перемешивания времени.

Гипотеза	Как проверялось	Результат
Простое сохранение текущей цены может быть сильным baseline	Persistence: next close = current close	Лучший RMSE на validation: 2.8433
Линейная модель должна хорошо работать из-за высокой автокорреляции цены	Ridge/ElasticNet по лагам, OHLCV и rolling-признакам	Близко к baseline, но хуже по RMSE
Деревья могут поймать нелинейности	DecisionTree	Хуже линейных моделей
Ансамбли деревьев могут улучшить качество	RandomForest/ExtraTrees в лёгкой конфигурации	Не обогнали baseline и Ridge
Directional ассигасу может показать пригодность для направления	Сравнение знака изменения цены	Около 50%, то есть надёжного сигнала направления нет

Метрики экспериментов:

model	MAE	RMSE	MAPE_%	R2	direction_accuracy_%	fit_seconds
Persistence baseline	1.9549	2.8433	0.044	0.9993	1.11	0
ElasticNet(alpha=0.001)	1.9631	2.8535	0.0442	0.9993	49.59	0.24
Ridge(alpha=1.0)	1.9762	2.869	0.0445	0.9993	50.55	0.09
RandomForest(tiny)	2.0806	2.9602	0.0469	0.9992	48.67	2.44
SGDRegressor	2.0901	3.0192	0.0471	0.9992	50.19	0.13
DecisionTree(max_depth=8)	2.1935	3.0593	0.0494	0.9992	49.35	0.85
ExtraTrees(tiny)	2.2219	3.3189	0.05	0.999	49.81	0.3
DummyRegressor(mean)	135.982	150.462	3.0448	-	49.6	0.08
				1.0487		




Figure 2: Сравнение RMSE

6. Финальная модель и интерпретируемость

Для деплоя сохранён артефакт `models/final_model.joblib` с Ridge-моделью. Причина выбора для сервиса: модель быстрая, стабильная, интерпретируемая и не создаёт тяжёлую зависимость для локального запуска.

Но честный итог такой: на тестовом срезе persistence-baseline оказался лучше по RMSE, чем Ridge:

- Ridge test RMSE: 6.3111;
- persistence test RMSE: 5.9451.

Поэтому API возвращает оба значения и поле `recommended_strategy`. В текущем артефакте рекомендация — `persistence_baseline`, потому что она честно лучше на тестовом RMSE. Ridge оставлен как ML-модель для демонстрации пайплайна и интерпретации.




Figure 3: Predicted vs actual

Интерпретация Ridge по модулю стандартизованных коэффициентов показывает, что основной вклад дают текущие и лаговые цены (Close, Open, close_lag_1, High, Low). Это ожидаемо для прогноза следующей минутной цены: модель в основном экстраполирует текущий уровень цены.




Figure 4: Интерпретируемость Ridge

7. Деплой

В CP3 добавлен локальный деплой:

- FastAPI: обязательный HTTP-интерфейс для запросов;
- Streamlit: простой UI для загрузки CSV и получения прогноза;
- Dockerfile и docker-compose.yml;
- пример payload: examples/sample_payload.json;
- тесты smoke-level: pytest.

Основные endpoints:

- GET /health — проверка, что сервис жив;
- GET /model-info — информация о модели и метриках;
- POST /predict — прогноз по последним свечам.

Команды запуска:

```
pip install -r requirements.txt
PYTHONPATH=src uvicorn app.main:app --reload
```

Или через Docker:

```
docker compose up --build
```

Скриншоты работы:

```
GET /health
{
  "status": "ok"
}
```

Figure 5: Health endpoint

```
POST /predict
{
  "recommended_prediction": 3823.8,
  "recommended_strategy": "persistence baseline",
  "model_prediction": 3823.7001115641024,
  "persistence_baseline_prediction": 3823.8,
  "delta_model_vs_current": -0.09988843589781027,
  "delta_model_vs_current_pct": -0.002612281915836956,
  "model_type": "Ridge(alpha=1.0, solver=lsqr)",
  "target": "next one-minute ETHUSD close price",
  "test_rmse_model": 6.311113635883866,
  "test_rmse_baseline": 5.945111810554947,
  "warning": "This is an educational one-minute forecast. It is not financial advice and should not be used for trading decisions."
}
```

Figure 6: Predict endpoint

Ссылка на видео работы деплоя: **TODO: вставить ссылку после записи локального запуска.**

8. Заключение и выводы

На CP3 подготовлен деплой и отчёт. Самый важный вывод по моделированию: для минутного прогноза цены ETHUSD простой persistence-baseline очень силён. Ridge и другие модели на контрольном срезе не дали честного улучшения по RMSE. Поэтому текущий сервис не стоит воспринимать как торговый инструмент: он демонстрирует воспроизводимый ML/deployment pipeline и честно возвращает baseline как рекомендуемый прогноз, если он лучше модели.

Что можно улучшить дальше:

- прогнозировать не цену, а доходность или направление;
- увеличить горизонт прогноза, например 5/15/60 минут;

```
Streamlit UI preview  
Title: ETHUSD one-minute forecast  
Upload: sample_candles.csv  
API URL: http://localhost:8000/predict  
  
Recommended next close: 3823.8000  
Model prediction: 3823.7001  
Persistence baseline: 3823.8000
```

Figure 7: Streamlit UI preview

- добавить внешние признаки: funding, order book, BTC price, volatility index;
- обучать и валидировать модель walk-forward способом;
- сравнить результат с полноценным CP2-артефактом, если он уже сохранён в репозитории.